

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN

Nhận diện giống chuối từ ảnh

Đồ án môn CS231 — Nhập môn Thị giác máy tính

Nhóm thực hiện: .....

Giảng viên: .....



Chào thầy/cô và các bạn. Nhóm trình bày đồ án nhận diện 4 giống chuối Bangladesh từ ảnh. Mục tiêu không chỉ là có mô hình chính xác mà là thử tất cả phương pháp đã học, so sánh bằng thực nghiệm và giải thích kết quả bằng tính chất của từng phương pháp.

Nội dung

1 Giới thiệu

2 Phương pháp

3 Kết quả thực nghiệm

4 Phần mở rộng: ba nhánh so sánh

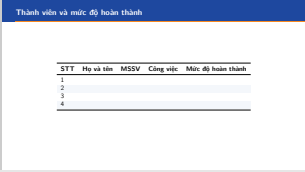
5 Kết luận



Bài trình bày gồm năm phần: giới thiệu bài toán và dữ liệu; phương pháp; kết quả 30 thí nghiệm và đánh giá cuối; phần mở rộng so sánh ba nhánh độc lập với pipeline gốc; ưu điểm, hạn chế và hướng phát triển.

Thành viên và mức độ hoàn thành

STT	Họ và tên	MSSV	Công việc	Mức độ hoàn thành
1				
2				
3				
4				

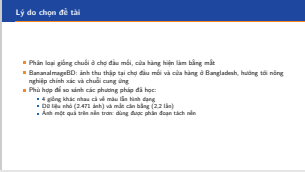

Thành viên và mức độ hoàn thành

STT	Họ và tên	MSSV	Công việc	Mức độ hoàn thành
1				
2				
3				
4				

Phần này nhóm tự điền: thành viên, công việc phụ trách và mức độ hoàn thành.

Lý do chọn đề tài

- Phân loại giống chuối ở chợ đầu mối, cửa hàng hiện làm bằng mắt
- BananaImageBD: ảnh thu thập tại chợ đầu mối và cửa hàng ở Bangladesh, hướng tới nông nghiệp chính xác và chuỗi cung ứng
- Phù hợp để so sánh các phương pháp đã học:
  - 4 giống khác nhau cả về màu lẫn hình dạng
  - Dữ liệu nhỏ (2.471 ảnh) và mất cân bằng (2,2 lần)
  - Ảnh một quả trên nền trơn: dùng được phân đoạn tách nền

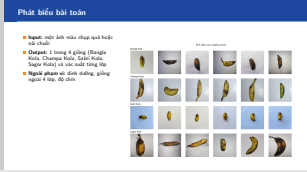


Bài toán có ý nghĩa thực tế và đồng thời là bài toán tốt để kiểm chứng các tính chất đã học: màu so với hình dạng, quá khớp khi dữ liệu ít, transfer learning, mất cân bằng dữ liệu.

Phát biểu bài toán

- **Input:** một ảnh màu chụp quả hoặc nải chuối
- **Output:** 1 trong 4 giống (Bangla Kola, Champa Kola, Sabri Kola, Sagor Kola) và xác suất từng lớp
- **Ngoài phạm vi:** dinh dưỡng, giống ngoài 4 lớp, độ chín

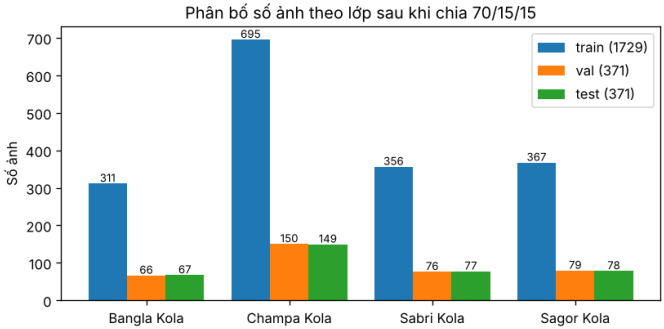


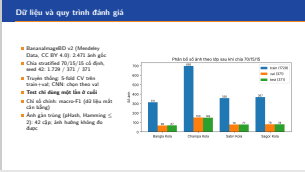


Input là ảnh màu, output là tên giống cùng xác suất 4 lớp. Hình bên phải là ảnh mẫu của 4 giống. Có thể thấy Sabri Kola thường là quả nhỏ trên nền xanh nhạt; chi tiết này quan trọng ở phần S2.

Dữ liệu và quy trình đánh giá

- BananaImageBD v2 (Mendeley Data, CC BY 4.0): 2.471 ảnh gốc
- Chia stratified 70/15/15 cố định, seed 42: 1.729 / 371 / 371
- Truyền thống: 5-fold CV trên train+val; CNN: chọn theo val
- **Test chỉ dùng một lần ở cuối**
- Chỉ số chính: macro-F1 (dữ liệu mất cân bằng)
- Ảnh gần trùng (pHash, Hamming $\leq$ 2): 42 cặp; ảnh hưởng không đo được





Quy trình đánh giá chốt từ đầu để mọi phương pháp so sánh được với nhau. Test chỉ dùng một lần. Chênh lệch nhỏ hơn độ lệch chuẩn giữa các fold thì nhóm kết luận là chưa đủ cơ sở phân biệt. Bảng ảnh gần trùng ở results/data/near_duplicates.json.

Phương pháp — hướng truyền thống

- **Đặc trưng màu:** histogram RGB, HSV (8,8,8), H-S; moment màu (9 chiều); màu chủ đạo k-means; CCV
- **Đặc trưng cạnh:** Roberts, Prewitt, Sobel, Laplacian $\rightarrow$ tổng theo hàng/cột (512 chiều)
- **HOG** tự cài đặt: 64$\times$128, cell 8$\times$8, 9 bin, block 16$\times$16 L2 $\rightarrow$ 3.780 chiều (lệch skimage $2{\cdot}10^{-7}$)
- **Ghép:** chuẩn hóa từng phần rồi ghép
- **Bộ phân lớp:** KNN (k, độ đo, uniform/distance, brute/kd/ball tree), Logistic Regression; Linear SVM làm bộ phân lớp bổ sung

Phương pháp — hướng truyền thống

- **Đặc trưng màu:** histogram RGB, HSV (8,8,8), H-S; moment màu (9 chiều); màu chủ đạo k-means; CCV
- **Đặc trưng cạnh:** Roberts, Prewitt, Sobel, Laplacian → tổng theo hàng/cột (512 chiều)
- **HOG** tự cài đặt: 64×128, cell 8×8, 9 bin, block 16×16 L2 → 3.780 chiều (lệch skimage 2.10^{-7})
- **Ghép:** chuẩn hóa từng phần rồi ghép
- **Bộ phân lớp:** KNN (k, đủ đo, uniform/distance, brute/kd/ball tree), Logistic Regression; Linear SVM làm bộ phân lớp bổ sung

Đây là tất cả đặc trưng và bộ phân lớp đã học. HOG được nhóm tự cài đặt theo các bước của bài giảng để có thể bỏ bước chuẩn hóa block cho thí nghiệm C2, và đã đối chiếu với skimage.

Phương pháp — CNN hai hướng

Hướng	Mô hình	Mô tả
A (bài giảng)	a_lenet	Kiểu LeNet-5, ảnh 64×64, học từ đầu
A (bài giảng)	a_dropout	2 Conv + Dense(128) + Dropout(0,5), ảnh 128×128
A (bài giảng)	a_vgg16	VGG16 ImageNet đóng băng + Dense(1024) + Dense(256)
B (lớn hơn)	b_mobilenetv3	MobileNetV3-Small: GĐ1 đóng băng, GĐ2 fine-tune + tăng cường
B (lớn hơn)	b_resnet50	ResNet50: GĐ1 đóng băng, GĐ2 mở khối conv5

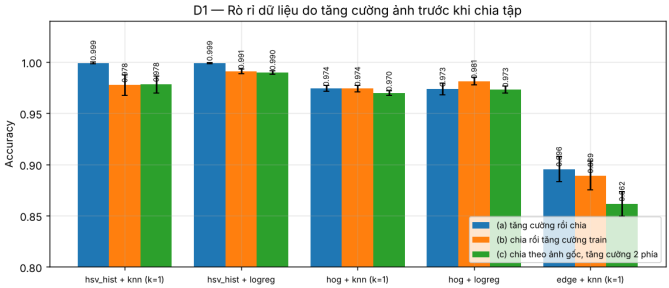
Phương pháp — CNN hai hướng

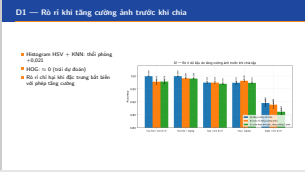
Hướng	Mô hình	Mô tả
A (bài giảng)	a_lenet	Kiểu LeNet-5, ảnh 64×64, học từ đầu
A (bài giảng)	a_dropout	2 Conv + Dense(128) + Dropout(0.5), ảnh 128×128
A (bài giảng)	a_vgg16	VGG16 ImageNet đóng băng + Dense(1024) + Dense(256)
B (tốn hơn)	b_mobilenetv3	MobileNetV3-Small: GD1 đóng băng, GD2 fine-tune + tăng cường
B (tốn hơn)	b_resnet50	ResNet50: GD1 đóng băng, GD2 mở khối conv5

Hướng A làm đúng các ví dụ trong bài giảng. Hướng B dùng kiến trúc ngoài bài giảng nhưng vẫn là khái niệm đã học: transfer learning. Chung: Adam, cross-entropy, dừng sớm theo macro-F1 trên val. Khi fine-tune, BatchNorm phải giữ đóng băng (slide N4).

D1 — Rò rỉ khi tăng cường ảnh trước khi chia

- Histogram HSV + KNN: thổi phồng +0,021
- HOG: ≈ 0 (trái dự đoán)
- Rò rỉ chỉ hại khi đặc trưng bất biến với phép tăng cường

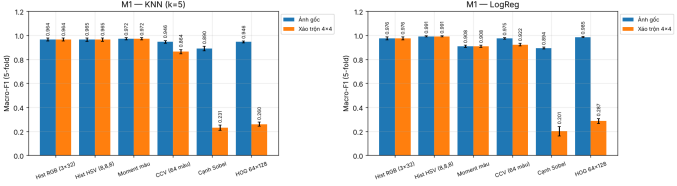


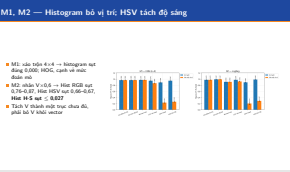


Dự đoán: tăng cường rồi mới chia làm bản sao của ảnh test nằm trong train nên kết quả bị thổi phồng. Đúng với histogram vì histogram gần như không đổi khi lật/xoay. Với HOG mức thổi phồng gần 0 vì bản lật có vector khác hẳn. Đây là lý do không dùng bản Augmented có sẵn. Bảng: results/D1/table.md.

M1, M2 — Histogram bỏ vị trí; HSV tách độ sáng

- M1: xáo trộn 4×4 → histogram sụt đúng 0,000; HOG, cạnh về mức đoán mò
- M2: nhân V×0,6 → Hist RGB sụt 0,76–0,87, Hist HSV sụt 0,66–0,67, **Hist H-S sụt ≤ 0,027**
- Tách V thành một trục chưa đủ, phải bỏ V khỏi vector

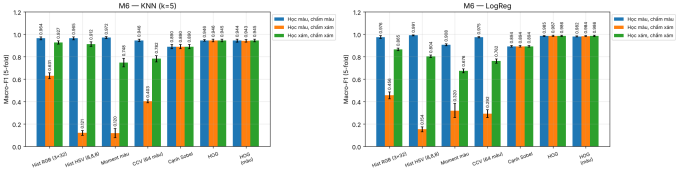


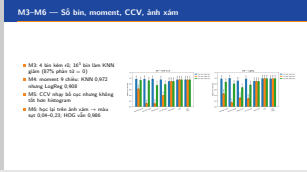


M1 khớp hoàn toàn: histogram không chứa thông tin vị trí. M2 khớp một phần: HSV đủ 3 kênh vẫn chứa V nên vẫn sụt mạnh; chỉ H-S bền. Bảng: results/M1/table.md, results/M2/table.md.

M3–M6 — Số bin, moment, CCV, ảnh xám

- M3: 4 bin kém rõ; 16^3 bin làm KNN giảm (87% phần tử = 0)
- M4: moment 9 chiều: KNN 0,972 nhưng LogReg 0,908
- M5: CCV nhạy bố cục nhưng không tốt hơn histogram
- M6: học lại trên ảnh xám → màu sụt 0,04–0,23; HOG vẫn 0,986

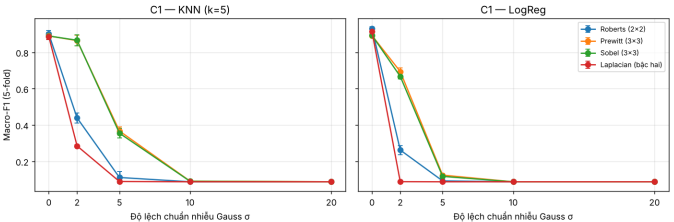


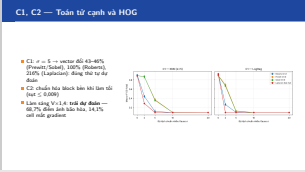


Hình là M6. Giống chuối phân biệt được cả bằng màu lẫn hình dạng. Moment màu ít chiều nên biên quyết định tuyến tính không đủ (liên hệ P6). CCV không giúp vì ảnh một quả nền trơn, hầu như mọi điểm ảnh đều thuộc vùng liên thông lớn.

C1, C2 — Toán tử cạnh và HOG

- C1: $\sigma = 5 \rightarrow$ vector đổi 43–46% (Prewitt/Sobel), 100% (Roberts), 216% (Laplacian): đúng thứ tự dự đoán
- C2: chuẩn hóa block bền khi làm tối (sụt $\leq$ 0,009)
- Làm sáng V$\times$1,4: **trái dự đoán** — 68,7% điểm ảnh bão hòa, 14,1% cell mất gradient

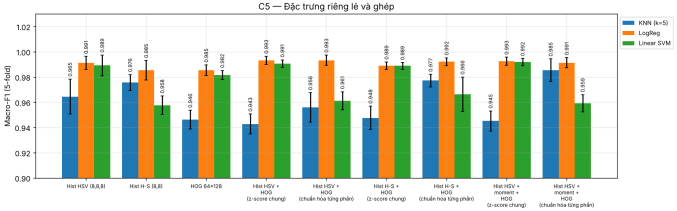


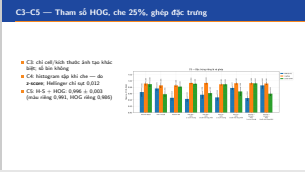


C1 khớp lý thuyết: toán tử có làm trơn bền hơn, đạo hàm bậc hai nhạy nhất. C2: phép làm sáng gây bão hòa, không còn là phép nhân tuyến tính nên chuẩn hóa không khử được. Bảng: results/C1, results/C2.

C3–C5 — Tham số HOG, che 25%, ghép đặc trưng

- C3: chỉ cell/kích thước ảnh tạo khác biệt; số bin không
- C4: histogram sập khi che — do **z-score**; Hellinger chỉ sụt 0,012
- C5: H-S + HOG: 0,996 ± 0,003 (màu riêng 0,991, HOG riêng 0,986)

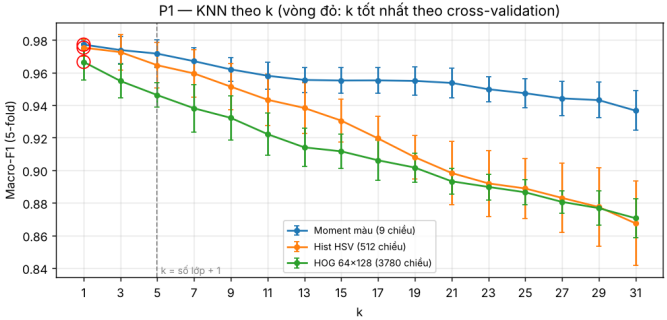


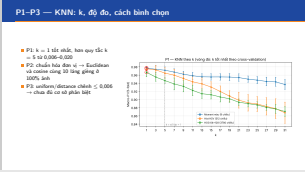


C4 là ví dụ cho thấy kết luận phụ thuộc cả bước chuẩn hóa chứ không chỉ đặc trưng. C5: ghép màu và hình dạng tốt nhất, nhưng hơn màu riêng chỉ 0,005, bằng độ lệch chuẩn.

P1–P3 — KNN: k, độ đo, cách bình chọn

- P1: k = 1 tốt nhất, hơn quy tắc k = 5 từ 0,006–0,020
- P2: chuẩn hóa đơn vị → Euclidean và cosine cùng 10 láng giềng ở 100% ảnh
- P3: uniform/distance chênh $\leq$ 0,006 → chưa đủ cơ sở phân biệt

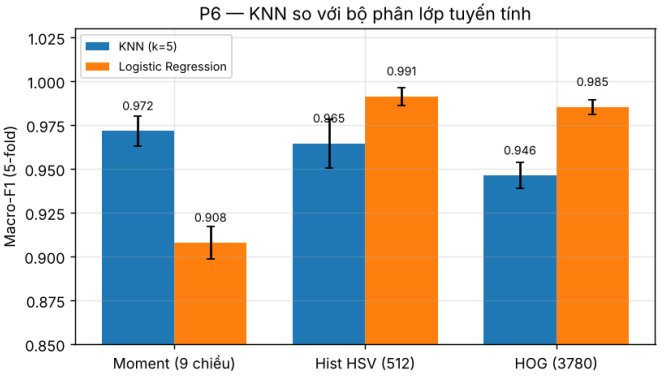


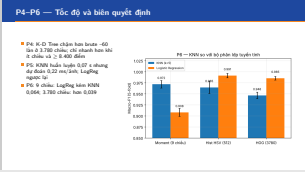


P1 trái với vế 'k nhỏ nhạy nhiễu' vì các lớp tách nhau rõ và có nhiều ảnh gần giống nhau. P2 kiểm chứng đúng điều lý thuyết dự đoán: trên vector đơn vị, khoảng cách Euclidean là hàm đơn điệu của cosine.

P4–P6 — Tốc độ và biên quyết định

- P4: K-D Tree chậm hơn brute ~60 lần ở 3.780 chiều; chỉ nhanh hơn khi ít chiều và $\geq$ 8.400 điểm
- P5: KNN huấn luyện 0,07 s nhưng dự đoán 0,22 ms/ảnh; LogReg ngược lại
- P6: 9 chiều: LogReg kém KNN 0,064; 3.780 chiều: hơn 0,039





Kết quả của cây tìm kiếm luôn trùng brute force, chỉ khác tốc độ. Bộ phân lớp tuyến tính cần nhiều chiều để các lớp tách được.

Cấu hình truyền thống đã chốt (5-fold CV)

Vai trò	Cấu hình	Macro-F1 (5-fold)	Accuracy
trad_color	Hist HSV (8,8,8) + LogReg C=0,1	0,991 ± 0,005	0,992
trad_edge	Cạnh Roberts + KNN k=1, Manhattan, ưu tiên điểm gần	0,955 ± 0,015	0,959
trad_hog	HOG 64×128 + LogReg C=0,1	0,986 ± 0,007	0,989
trad_fusion	Hist H-S + HOG + LogReg C=100, chuẩn hóa từng phần	0,996 ± 0,003	0,997

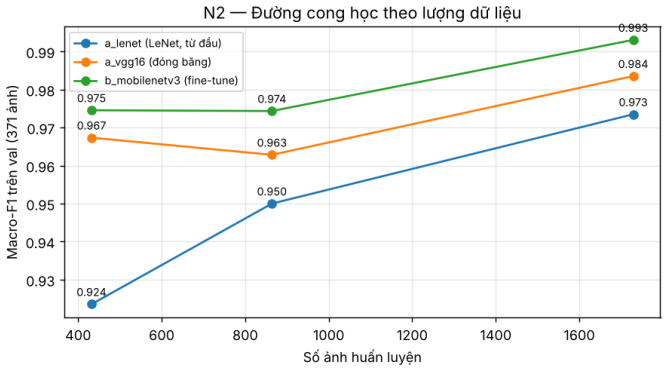
Cấu hình truyền thống đã chốt (5-fold CV)

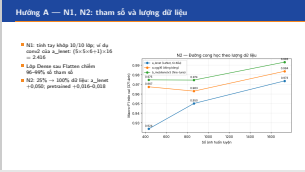
Vai trò	Cấu hình	Macro-F1 (5-fold)	Accuracy
trad_color	Hist HSV (8,8,8) + LogReg C=0,1	0,991 ± 0,005	0,992
trad_edge	Cạnh Roberts + KNN k=1, Manhattan, xu tiến điểm gần	0,955 ± 0,015	0,959
trad_hog	HOG 64 × 128 + LogReg C=0,1	0,988 ± 0,007	0,989
trad_fusion	Hist H-S + HOG + LogReg C=100, chuẩn hóa từng phần	0,996 ± 0,003	0,997

Sau khi quét siêu tham số: cấu hình ghép H-S + HOG + Logistic Regression tốt nhất, macro-F1 0,996 ± 0,003.

Hướng A — N1, N2: tham số và lượng dữ liệu

- N1: tính tay khớp 10/10 lớp; ví dụ conv2 của a_lenet: $(5\times5\times6+1)\times16 = 2.416$
- Lớp Dense sau Flatten chiếm 96–99% số tham số
- N2: 25% → 100% dữ liệu: a_lenet +0,050; pretrained +0,016–0,018

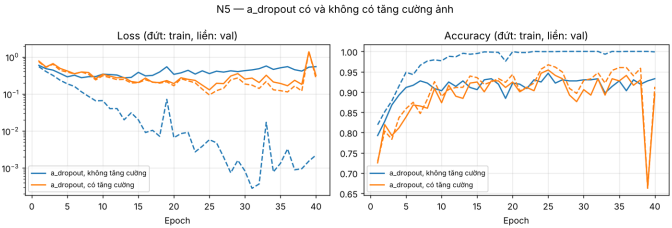




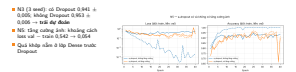
Ví dụ tính tay số tham số. Đường cong học cho thấy mô hình học từ đầu cần nhiều dữ liệu hơn; với 25% dữ liệu, mô hình pretrained đã ngang a_lenet dùng đủ dữ liệu.

Hướng A — N3, N5: Dropout và tăng cường ảnh

- N3 (3 seed): có Dropout 0,941 $\pm$ 0,005; không Dropout 0,953 $\pm$ 0,006 $\rightarrow$ **trái dự đoán**
- N5: tăng cường ảnh: khoảng cách loss val − train 0,542 $\rightarrow$ 0,054
- Quá khớp nằm ở lớp Dense trước Dropout



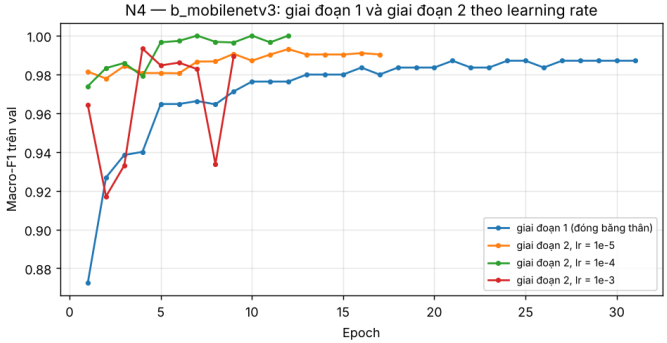
Hướng A — N3, N5: Dropout và tăng cường ảnh

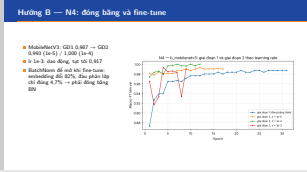


Dropout(0,5) đặt sau lớp Dense chứa 99% tham số nên không chặn được quá khớp ở đó. Tăng cường ảnh tác động vào đầu vào nên hiệu quả hơn nhiều.

Hướng B — N4: đóng băng và fine-tune

- MobileNetV3: GĐ1 0,987 → GĐ2 0,993 (1e-5) / 1,000 (1e-4)
- lr 1e-3: dao động, tụt tới 0,917
- BatchNorm để mở khi fine-tune: embedding đổi 82%, đầu phân lớp chỉ đúng 4,7% → phải đóng băng BN

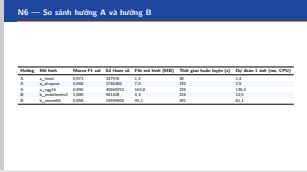




Fine-tune giúp nhưng mức tăng nhỏ vì giai đoạn 1 đã cao. Learning rate lớn làm mất ổn định. Chi tiết BatchNorm là bài học cài đặt quan trọng: results/N4/table_batchnorm.md.

N6 — So sánh hướng A và hướng B

Hướng	Mô hình	Macro-F1 val	Số tham số	File mô hình (MB)	Thời gian huấn luyện (s)	Dự đoán 1 ảnh (ms, CPU)
A	a_lenet	0,973	337976	1,4	30	1,4
A	a_dropout	0,948	1746260	7,0	192	2,5
A	a_vgg16	0,990	40669252	162,8	226	130,4
B	b_mobilenetv3	1,000	941428	4,3	216	12,5
B	b_resnet50	0,998	23595908	95,1	591	61,1

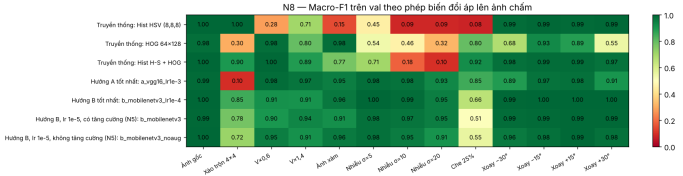

N6 — So sánh hướng A và hướng B

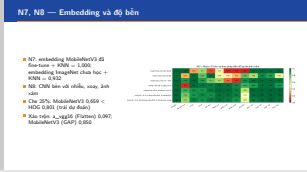
Hướng	Mô hình	Macro-F1 val	Số tham số	File mô hình (MB)	Thời gian hoàn luận (s)	Dự đoán 1 ảnh (ms, CPU)
A	a_lenet	0.903	61578...	7.2	39	2.4
A	a_vgg16	0.993	134268...	512.3	163	130.5
A	a_rdp16	0.990	40690052	162.8	226	130.4
B	a_mobilenetv3	0.990	941438	4.3	284	12.5
B	a_mnasnet0	0.996	2334900...	95.1	981	61.1

Hướng B tốt hơn. Nhưng 'lớn hơn' không có nghĩa là nặng hơn: MobileNetV3 chỉ 0,94 triệu tham số, 4,3 MB, 12,5 ms mỗi ảnh, trong khi a_vgg16 của hướng A nặng 163 MB và mất 130 ms.

N7, N8 — Embedding và độ bền

- N7: embedding MobileNetV3 đã fine-tune + KNN = 1,000; embedding ImageNet chưa học + KNN = 0,932
- N8: CNN bền với nhiễu, xoay, ảnh xám
- Che 25%: MobileNetV3 0,659 < HOG 0,801 (trái dự đoán)
- Xáo trộn: a_vgg16 (Flatten) 0,097; MobileNetV3 (GAP) 0,850

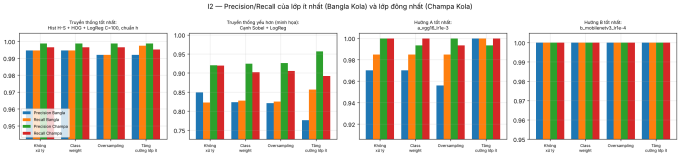




Không phương pháp nào bền với mọi thay đổi; mỗi phương pháp bền với đúng loại thay đổi mà cấu trúc của nó bất biến.

I1, I2 — Mất cân bằng dữ liệu

- I1: luôn đoán lớp đông nhất: accuracy 0,402, macro-F1 0,143
- KNN k=31: accuracy 0,884 nhưng recall Sagor 0,552
- I2: ở mô hình yếu, các cách xử lý đổi precision lấy recall; ở mô hình mạnh không tác động

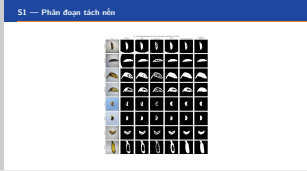




Accuracy có thể che khuất lớp bị nhận kém; vì vậy chỉ số chính là macro-F1. Với tỉ lệ 2,2 lần, mất cân bằng không phải vấn đề chính.

S1 — Phân đoạn tách nền

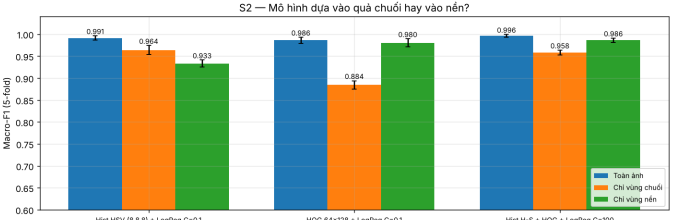


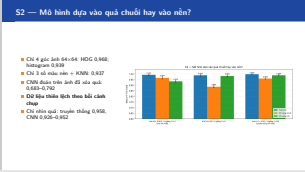


Ngưỡng toàn cục và thích nghi tách cả vết thâm thành nền. Các cách dựa trên màu (k-means, Otsu trên khoảng cách màu tới nền) cho mask liền nhất. Không có nhãn mask nên đánh giá định tính, kèm số mảnh rời và tỉ lệ lỗ thủng.

S2 — Mô hình dựa vào quả chuối hay vào nền?

- Chỉ 4 góc ảnh 64×64: HOG 0,968; histogram 0,939
- Chỉ 3 số màu nền + KNN: 0,937
- CNN đoán trên ảnh đã xóa quả: 0,683–0,792
- **Dữ liệu thiên lệch theo bối cảnh chụp**
- Chỉ nhìn quả: truyền thống 0,958, CNN 0,926–0,952

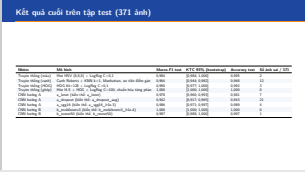




Đây là phát hiện quan trọng nhất. Mỗi giống được chụp trong điều kiện riêng: nền Sabri xanh hơn, quả Sabri chiếm 5,4% ảnh so với 22% ở Sagor. Vì vậy con số gần 100% là độ chính xác trên bộ dữ liệu này, không phải trong điều kiện bất kỳ.

Kết quả cuối trên tập test (371 ảnh)

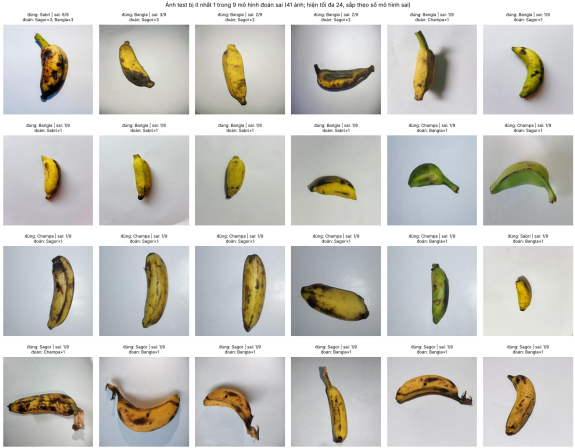
Nhóm	Mô hình	Macro-F1 test	KTC 95% (bootstrap)	Accuracy test	Số ảnh sai / 371
Truyền thống (màu)	Hist HSV (8,8,8) + LogReg C=0,1	0,994	[0,984; 1,000]	0,995	2
Truyền thống (cạnh)	Cạnh Roberts + KNN k=1, Manhattan, ưu tiên điểm gần	0,964	[0,944; 0,982]	0,968	12
Truyền thống (HOG)	HOG 64×128 + LogReg C=0,1	0,990	[0,977; 1,000]	0,992	3
Truyền thống (ghép)	Hist H-S + HOG + LogReg C=100, chuẩn hóa từng phần	1,000	[1,000; 1,000]	1,000	0
CNN hướng A	a_lenet (biến thể: a_lenet)	0,978	[0,960; 0,993]	0,981	7
CNN hướng A	a_dropout (biến thể: a_dropout_aug)	0,942	[0,917; 0,965]	0,943	21
CNN hướng A	a_vgg16 (biến thể: a_vgg16_lr1e-3)	0,986	[0,971; 0,997]	0,989	4
CNN hướng B	b_mobilenetv3 (biến thể: b_mobilenetv3_lr1e-4)	1,000	[1,000; 1,000]	1,000	0
CNN hướng B	b_resnet50 (biến thể: b_resnet50)	0,997	[0,988; 1,000]	0,997	1

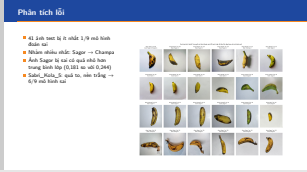


Truyền thống tốt nhất (H-S + HOG + LogReg) và b_mobilenetv3 đều đúng 371/371 ảnh, macro-F1 1.000 và 1.000. a_vgg16 tốt nhất hướng A với 0.986. Khoảng tin cậy chồng lên nhau nên không tuyên bố hơn kém giữa các mô hình dẫn đầu.

Phân tích lỗi

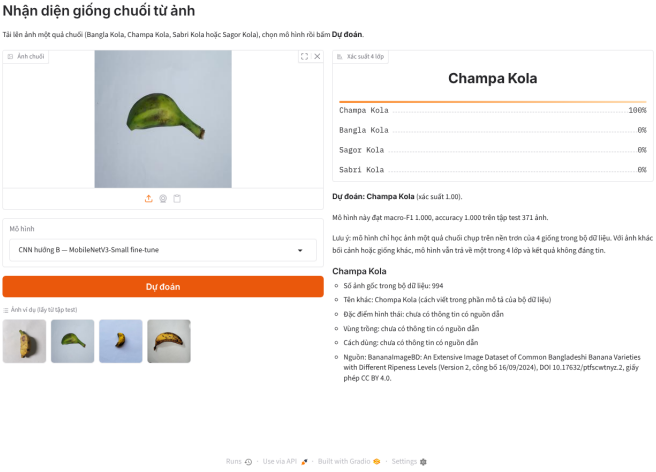
- 41 ảnh test bị ít nhất 1/9 mô hình đoán sai
- Nhầm nhiều nhất: Sagor → Champa
- Ảnh Sagor bị sai có quả nhỏ hơn trung bình lớp (0,181 so với 0,244)
- Sabri_Kola_5: quả to, nền trắng → 6/9 mô hình sai

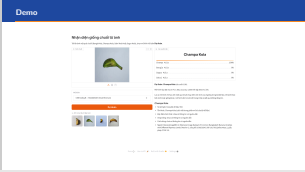




Lỗi khớp với thiên lệch đo ở S2: ảnh không giống ảnh điển hình của lớp về kích thước quả và nền thì dễ bị đoán sai.

Demo

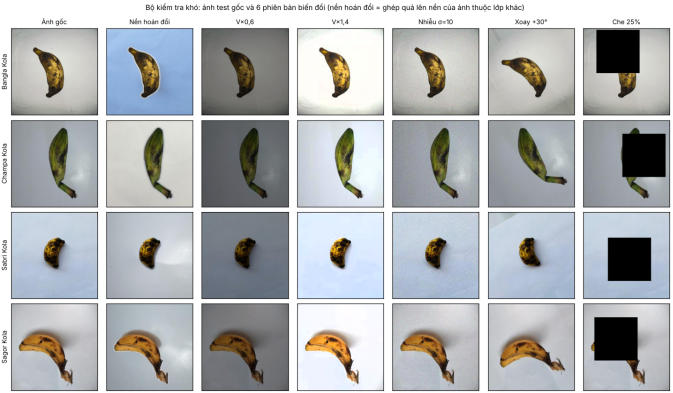

Nhận diện giống chuối từ ảnh
Tải lên ảnh một quả chuối (Bangla Kola, Champa Kola, Sabri Kola hoặc Sagor Kola), chọn mô hình rồi bấm Dự đoán.
Ảnh chuối
Xác suất 4 lớp
Champa Kola
Champa Kola 100%
Bangla Kola 6%
Sagor Kola 6%
Sabri Kola 6%
Dự đoán: Champa Kola (xác suất 1.00).
Mô hình này đạt macro-F1 1.000, accuracy 1.000 trên tập test 371 ảnh.
Lưu ý: mô hình chỉ học ảnh một quả chuối chụp trên nền trơn của 4 giống trong bộ dữ liệu. Với ảnh khác bối cảnh hoặc giống khác, mô hình vẫn trả về một trong 4 lớp và kết quả không đáng tin.
Mô hình
CNN hướng B — MobileNetV3-Small fine-tune
Champa Kola
Số ảnh gốc trong bộ dữ liệu: 994
Tên khác: Chompa Kola (cách viết trong phần mô tả của bộ dữ liệu)
Đặc điểm hình thái: chưa có thông tin có nguồn dẫn
Vùng trồng: chưa có thông tin có nguồn dẫn
Cách dùng: chưa có thông tin có nguồn dẫn
Nguồn: BananaImageBD: An Extensive Image Dataset of Common Bangladeshi Banana Varieties with Different Ripeness Levels (Version 2, công bố 16/09/2024), DOI 10.17632/ptfscwtnyz.2, giấy phép CC BY 4.0.
Dự đoán
Ảnh ví dụ (lấy từ tập test)
Runs · Use via API · Built with Gradio · Settings



Chạy: python app/app.py. Tải ảnh, chọn mô hình, nhận giống và xác suất 4 lớp. Thông tin giống chỉ ghi những gì có nguồn.

Mở rộng — ba nhánh độc lập và bộ kiểm tra khó

- **G**: pipeline gốc (mốc)
- **X**: xử lý dữ liệu do nhóm thiết kế
- **T**: bản Augmented của tác giả bộ dữ liệu
- **B**: phương pháp của bài báo (Ergün 2025)
- Mỗi nhánh đổi một thứ so với G; cùng 371 ảnh test gốc
- Bộ kiểm tra khó: 6 phép biến đổi; **điểm bền** = trung bình macro-F1





Trên ảnh gốc, hai cấu hình của pipeline gốc đã đúng 371/371 ảnh nên không còn chỗ để so sánh. Vì vậy mỗi mô hình được chấm thêm trên 6 phiên bản biến đổi của tập test, trong đó nền hoán đổi là ghép quả chuối lên nền của ảnh thuộc lớp khác. Ba nhánh độc lập, không chồng lên nhau.

Nhánh G trên bộ kiểm tra khó

Mô hình	Macro-F1 test	Nền hoán đổi	V×0,6	V×1,4	Nhiễu σ=10	Xoay +30°	Che 25%	Điểm bền
Hist HSV (8,8,8) + LogReg C=0,1	0,994	0,726	0,304	0,673	0,086	0,983	0,150	0,487
Cạnh Roberts + KNN k=1, Manhattan, ưu tiên điểm gần	0,964	0,759	0,691	0,901	0,085	0,730	0,755	0,654
HOG 64×128 + LogReg C=0,1	0,990	0,145	0,987	0,776	0,484	0,505	0,805	0,617
Hist H-S + HOG + LogReg C=100, chuẩn hóa từng phần	1,000	0,410	0,997	0,856	0,172	0,972	0,959	0,728
a_lenet	0,978	0,744	0,979	0,977	0,978	0,874	0,469	0,837
a_dropout	0,942	0,855	0,864	0,932	0,940	0,925	0,100	0,769
a_vgg16	0,986	0,657	0,979	0,963	0,984	0,887	0,843	0,886
b_mobilenetv3	1,000	0,794	0,919	0,890	0,989	1,000	0,659	0,875
b_resnet50	0,997	0,792	0,916	0,966	0,990	0,993	0,714	0,895

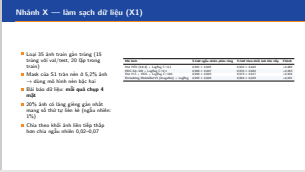


Macro-F1 trên ảnh gốc 0,94–1,00 nhưng điểm bền chỉ 0,49–0,90. Nền hoán đổi làm mọi cấu hình tụt: HOG còn 0,145, cấu hình truyền thống tốt nhất còn 0,410, b_mobilenetv3 còn 0,794. Đây là xác nhận thứ hai cho kết luận của S2: mô hình dựa một phần vào nền.

Nhánh X — làm sạch dữ liệu (X1)

- Loại 35 ảnh train gần trùng (15 trùng với val/test, 20 lặp trong train)
- Mask của S1 tràn nền ở 5,2% ảnh → dùng mô hình nền bậc hai
- Bài báo dữ liệu: **mỗi quả chụp 4 mặt**
- 20% ảnh có láng giềng gần nhất mang số thứ tự liền kề (ngẫu nhiên: 1%)
- Chia theo khối ảnh liên tiếp thấp hơn chia ngẫu nhiên 0,02–0,07

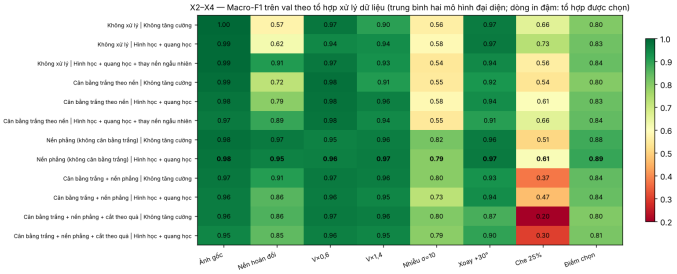
Mô hình	5-fold ngẫu nhiên phân tầng	5-fold theo khối ảnh liên tiếp	Chênh
Hist HSV (8,8,8) + LogReg C=0,1	0,991 ± 0,005	0,922 ± 0,042	+0,069
HOG 64×128 + LogReg C=0,1	0,986 ± 0,007	0,933 ± 0,062	+0,053
Hist H-S + HOG + LogReg C=100	0,996 ± 0,003	0,973 ± 0,017	+0,024
Embedding MobileNetV3 (ImageNet) + LogReg	0,995 ± 0,005	0,964 ± 0,025	+0,031

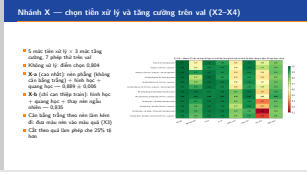


Pipeline gốc chỉ resize ảnh. Bước làm sạch loại ảnh gần trùng khỏi train. Phát hiện quan trọng: ảnh cùng quả hoặc cùng đợt chụp nằm ở cả hai phía khi chia ngẫu nhiên, nên cross-validation ngẫu nhiên lạc quan hơn chia theo khối ảnh liên tiếp. Bảng: results/E1_xu_ly/table_blocked_cv.md, table_adjacent.md.

Nhánh X — chọn tiền xử lý và tăng cường trên val (X2–X4)

- 5 mức tiền xử lý × 3 mức tăng cường, 7 phép thử trên val
- Không xử lý: điểm chọn 0,804
- **X-a** (cao nhất): nền phẳng (không cân bằng trắng) + hình học + quang học — 0,889 ± 0,006
- **X-b** (chỉ can thiệp train): hình học + quang học + thay nền ngẫu nhiên — 0,835
- Cân bằng trắng theo nền làm kém đi: đưa màu nền vào màu quả (X3)
- Cắt theo quả làm phép che 25% tệ hơn





Điểm chọn là trung bình macro-F1 trên val của ảnh gốc và 6 phép thử khó, với hai mô hình đại diện; sai số tính bằng bootstrap. Tách nền (nền phẳng) là bước có tác dụng lớn nhất. Cân bằng trắng theo nền bị loại: hệ số tính từ màu nền rồi nhân vào cả quả chuối, nên khi nền đổi thì màu quả lệch 12,9 đơn vị Lab. Nhóm chạy đủ pipeline cho hai biến thể X-a và X-b. Bảng: results/E1_xu_ly/table_selection.md, table_wb_leak.md.

Nhánh X-a — 9 cấu hình với nền phẳng + tăng cường

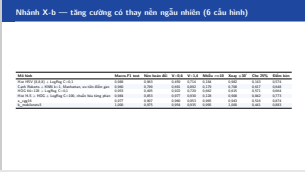
Mô hình	Macro-F1 test	Nền hoán đổi	V×0,6	V×1,4	Nhiễu σ=10	Xoay +30°	Che 25%	Điểm bền
Hist HSV (8,8,8) + LogReg C=0,1	0,993	0,966	0,834	0,784	0,354	0,993	0,169	0,683
Cạnh Roberts + KNN k=1, Manhattan, ưu tiên điểm gần	0,842	0,838	0,799	0,820	0,792	0,686	0,381	0,719
HOG 64×128 + LogReg C=0,1	0,828	0,836	0,810	0,831	0,822	0,629	0,294	0,704
Hist H-S + HOG + LogReg C=100, chuẩn hóa từng phần	0,982	0,951	0,978	0,979	0,651	0,974	0,805	0,890
a_lenet	0,922	0,925	0,861	0,846	0,922	0,797	0,317	0,778
a_dropout	0,959	0,959	0,880	0,942	0,962	0,946	0,207	0,816
a_vgg16	0,958	0,951	0,933	0,954	0,964	0,926	0,413	0,857
b_mobilenetv3	0,995	0,995	0,943	0,915	0,988	0,998	0,450	0,881
b_resnet50	0,997	0,997	0,983	0,956	0,985	0,990	0,397	0,885



X-a: thay nền bằng màu trắng phẳng, giữ nguyên màu quả, áp dụng cho cả ảnh train lẫn ảnh cần dự đoán; train được thêm 2 bản tăng cường mỗi ảnh. Cột nền hoán đổi gần bằng cột ảnh gốc ở mọi cấu hình: mô hình không còn dựa vào nền. Đổi lại HOG, cạnh, a_lenet, a_vgg16 mất điểm trên ảnh gốc, và phép che 25% làm hỏng bước phân đoạn.

Nhánh X-b — tăng cường có thay nền ngẫu nhiên (6 cấu hình)

Mô hình	Macro-F1 test	Nền hoán đổi	V×0,6	V×1,4	Nhiễu σ=10	Xoay +30°	Che 25%	Điểm bền
Hist HSV (8,8,8) + LogReg C=0,1	0,988	0,963	0,459	0,714	0,184	0,982	0,143	0,574
Cạnh Roberts + KNN k=1, Manhattan, ưu tiên điểm gần	0,960	0,799	0,691	0,892	0,179	0,708	0,617	0,648
HOG 64×128 + LogReg C=0,1	0,953	0,495	0,922	0,720	0,662	0,615	0,571	0,664
Hist H-S + HOG + LogReg C=100, chuẩn hóa từng phần	0,984	0,853	0,977	0,930	0,128	0,908	0,842	0,773
a_vgg16	0,977	0,907	0,960	0,953	0,965	0,943	0,516	0,874
b_mobilenetv3	1,000	0,975	0,954	0,935	0,995	1,000	0,441	0,883

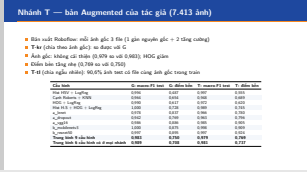


X-b: không đổi ảnh lúc dự đoán; mỗi ảnh train có thêm 2 bản mà quả chuối được ghép lên nền của một ảnh train bất kỳ. b_mobilenetv3 vẫn sai 0/371 ảnh gốc và đạt 0,975 khi nền bị hoán đổi (pipeline gốc: 0,794). Đây là lựa chọn cân bằng nhất cho mô hình tốt nhất; mô hình này có trong demo.

Nhánh T — bản Augmented của tác giả (7.413 ảnh)

- Bản xuất Roboflow: mỗi ảnh gốc 3 file (1 gần nguyên gốc + 2 tăng cường)
- **T-kr** (chia theo ảnh gốc): so được với G
- Ảnh gốc: không cải thiện (0,979 so với 0,983); HOG giảm
- Điểm bền tăng nhẹ (0,769 so với 0,750)
- **T-tl** (chia ngẫu nhiên): 90,6% ảnh test có file cùng ảnh gốc trong train

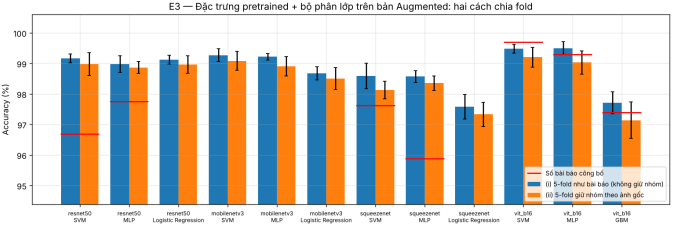
Cấu hình	G: macro-F1 test	G: điểm bền	T: macro-F1 test	T: điểm bền
Hist HSV + LogReg	0,994	0,487	0,997	0,555
Cạnh Roberts + KNN	0,964	0,654	0,948	0,689
HOG + LogReg	0,990	0,617	0,972	0,620
Hist H-S + HOG + LogReg	1,000	0,728	0,989	0,745
a_lenet	0,978	0,837	0,966	0,780
a_dropout	0,942	0,769	0,963	0,796
a_vgg16	0,986	0,886	0,985	0,905
b_mobilenetv3	1,000	0,875	0,998	0,909
b_resnet50	0,997	0,895	0,997	0,924
Trung bình 9 cấu hình	**0,983**	**0,750**	**0,979**	**0,769**
Trung bình 6 cấu hình có ở mọi nhánh	**0,989**	**0,708**	**0,981**	**0,737**

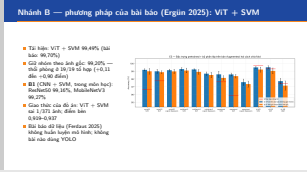


Bản Augmented của tác giả không giúp trên ảnh gốc, giúp một ít về độ bền ở đúng các phép có trong công thức tăng cường. Chia ngẫu nhiên bộ 7.413 ảnh gây rò rỉ: 90,6% ảnh test có anh em trong train. Bảng: results/E2_aug_tac_gia/.

Nhánh B — phương pháp của bài báo (Ergün 2025): ViT + SVM

- Tái hiện: ViT + SVM 99,49% (bài báo: 99,70%)
- Giữ nhóm theo ảnh gốc: 99,20% — thổi phồng ở 19/19 tổ hợp (+0,11 đến +0,90 điểm)
- **B1** (CNN + SVM, trong môn học): ResNet50 99,16%, MobileNetV3 99,27%
- Giao thức của đồ án: ViT + SVM sai 1/371 ảnh; điểm bền 0,919–0,937
- Bài báo dữ liệu (Ferdaus 2025) không huấn luyện mô hình; không bài nào dùng YOLO





Nhóm tái hiện được kết quả chính của bài báo, nhưng khoảng cách ViT so với CNN nhỏ hơn bài báo công bố nhiều (dưới 1 điểm thay vì 3 điểm). Giao thức 5-fold trên bản Augmented có rò rỉ nhỏ nhưng nhất quán. Đặc trưng ViT bền hơn CNN trên bộ kiểm tra khó, đổi lại nặng và chậm hơn khoảng 23 lần. Bảng: results/E3_bai_bao/table_protocols.md, table_test.md.

So sánh bốn nhánh qua cấu hình đại diện

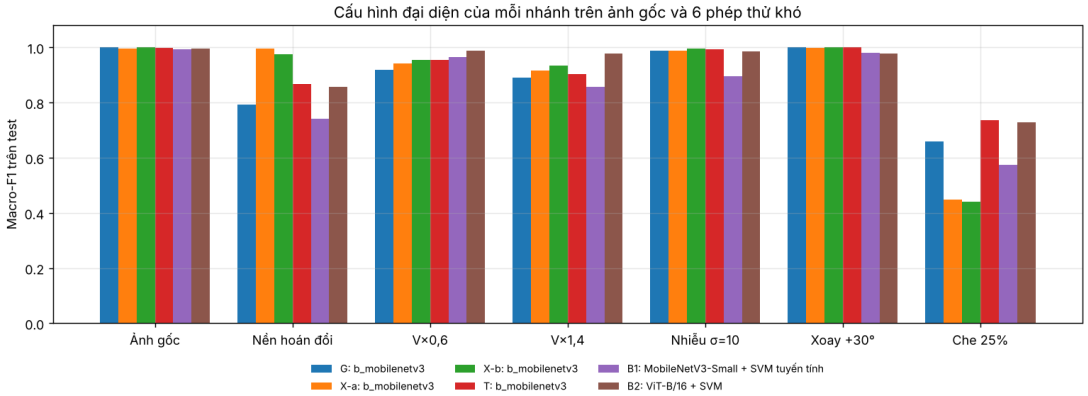
Nhánh	Cấu hình đại diện	Ảnh gốc	Nền hoán đổi	V×0,6	V×1,4	Nhiễu σ=10	Xoay +30°	Che 25%	Điểm bền
G — pipeline gốc	b_mobilenetv3	1,000	0,794	0,919	0,890	0,989	1,000	0,659	0,875
X-a — xử lý dữ liệu: tiền xử lý lúc suy luận	b_mobilenetv3	0,995	0,995	0,943	0,915	0,988	0,998	0,450	0,881
X-b — xử lý dữ liệu: tăng cường có thay nền	b_mobilenetv3	1,000	0,975	0,954	0,935	0,995	1,000	0,441	0,883
T — Augmented của tác giả (không rõ rì)	b_mobilenetv3	0,998	0,867	0,954	0,904	0,993	1,000	0,736	0,909
B1 — bài báo, trong phạm vi môn học (CNN + bộ phân lớp)	MobileNetV3-Small + SVM tuyến tính	0,993	0,742	0,965	0,856	0,897	0,981	0,575	0,836
B2 — bài báo, đúng phương pháp (ViT + SVM)	ViT-B/16 + SVM	0,997	0,857	0,990	0,978	0,986	0,978	0,728	0,919

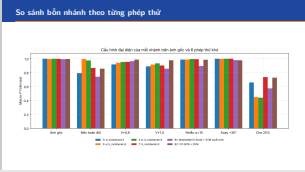

So sánh bốn nhánh qua cấu hình đại diện

Nhánh	Cấu hình đại diện	Acc. gộc	Acc. hoàn chỉnh	V-10.0	V-1.0	Nhiễu ×1.00	Xoay ±30°	Che 20%	Nhiễu đen
A — cnn-16 (16 lớp)	cnn_16	0.984	0.984	0.974	0.974	0.984	0.984	0.984	0.984
B.1 — cnn-32 (32 lớp, 32×32, 32 kq/16b)	b1_cnn32bit32x32	0.984	0.984	0.974	0.974	0.984	0.984	0.984	0.984
B.2 — cnn-32 (32 lớp, 16kq/16b)	b2_cnn32bit16x32	0.984	0.984	0.974	0.974	0.984	0.984	0.984	0.984
B.3 — cnn-32 (32 lớp, 8kq/16b)	b3_cnn32bit8x32	0.984	0.984	0.974	0.974	0.984	0.984	0.984	0.984
C — bộ lọc cứng được chọn khi huấn luyện	MaskedBankClassifier — 8 bộ lọc cứng	0.984	0.984	0.974	0.974	0.984	0.984	0.974	0.974
D — cnn-mini (mạng phụng sự)	TFT-Net — 1 khối	0.984	0.984	0.974	0.974	0.984	0.984	0.974	0.974

Mỗi nhánh một cấu hình đại diện, chọn theo điểm lúc phát triển. Trên ảnh gốc các nhánh ngang nhau (0 đến vài ảnh sai). Khác biệt nằm ở bộ kiểm tra khó. Bảng: results/so_sanh_nhanh/table_arms.md, table_stress.md, table_models.md.

So sánh bốn nhánh theo từng phép thử





Hình cho thấy mỗi nhánh mạnh ở phép thử nào. Không nhánh nào tốt nhất ở mọi phép thử.

Ưu điểm và hạn chế

- **Ưu điểm**
  - 30 thí nghiệm, mỗi nhận định có bảng hoặc hình; ghi cả kết quả trái dự đoán
  - Quy trình đánh giá chặt: test dùng một lần, CV, độ lệch chuẩn, khoảng tin cậy
  - Mô hình 4,3 MB, 12,5 ms/ảnh, đúng 371/371 ảnh test
  - Chạy lại toàn bộ bằng một lệnh
  - Đối chiếu với bài báo và bản Augmented của tác giả trên cùng tập test
- **Hạn chế**
  - Thiên lệch theo bối cảnh chụp (S2): chỉ nhìn nền vẫn đạt 0,93–0,99
  - Mỗi quả chụp nhiều mặt, chia ngẫu nhiên không tách theo quả: lạc quan 0,02–0,07 (X1)
  - Test nhỏ; bộ kiểm tra khó là biến đổi tổng hợp, chưa có ảnh thật ngoài bối cảnh
- **Hướng phát triển:** chia dữ liệu theo quả; ảnh cùng bối cảnh cho 4 giống



Nhóm nhấn mạnh hạn chế thiên lệch nền vì nó quyết định cách hiểu con số 100%.

Tài liệu tham khảo

- BananaImageBD, Mendeley Data v2, DOI 10.17632/ptfscwtnyz.2 (CC BY 4.0)
- Bài giảng CS231
- Ferdaus et al. 2025, Data in Brief 58, 111239; Ergün 2025, Scientific Reports 15, 10366
- Dalal & Triggs 2005 (HOG); Pass et al. 1996 (CCV); Stricker & Orengo 1995 (moment màu); Otsu 1979
- LeCun et al. 1998; Simonyan & Zisserman 2015; He et al. 2016; Howard et al. 2019
- Srivastava et al. 2014 (Dropout); Ioffe & Szegedy 2015 (BatchNorm); Dosovitskiy et al. 2021 (ViT); scikit-learn, TensorFlow/Keras, OpenCV

Danh sách đầy đủ ở mục 7 của báo cáo. Cảm ơn thầy/cô và các bạn đã lắng nghe.

Tài liệu tham khảo

- BananalmageBD, Mendeley Data v2, DOI 10.17632/ptfwcwtnyz.2 (CC BY 4.0)
- Bài giảng CS231
- Ferdaus et al. 2025, Data in Brief 58, 111239; Ergin 2025, Scientific Reports 15, 10366
- Dalal & Triggs 2005 (HOG); Paas et al. 1996 (CCV); Stricker & Orengo 1995 (moment màu); Otsu 1979
- LeCun et al. 1998; Simonyan & Zisserman 2015; He et al. 2016; Howard et al. 2019
- Srivastava et al. 2014 (Dropout); Ioffe & Szegedy 2015 (BatchNorm); Dosovitskiy et al. 2021 (ViT); scikit-learn, TensorFlow/Keras, OpenCV